


음악 스트리밍 구독자 이탈 방지

KKeeper

KKBOX 데이터 기반 고객 이탈 예측 · 마케팅 지원 서비스



목차

01

문제 정의

이탈 전 행동 변화와 프로젝트 목표

02

데이터

KKBox 6 개 테이블

03

데이터 샘플링

10 만 명 층화 추출

04

EDA

누가, 어떤 상태에서 이탈하는가

05

데이터 전처리

결측치 · 중복 · 피처 생성

06

모델링 및 모델 선정

Boosting 비교 → LightGBM

07

XAI 분석 및 고객 클러스터링


SHAP · K-Means 4 개 유형

08


서비스 핵심 기능

KKeeper 워크스페이스

이탈 전 나타나는 3 단계 행동 변화



그래서 풀어야 할 문제



프로젝트 목표 — 누가 · 왜 · 어떻게

01

고객 단위 통합

분산된 회원 · 결제 · 로그를
고객 한 명 단위로

회원 · 결제 · 로그

02

이탈 위험 예측

통합 데이터로 고객별
이탈 확률 산출

LightGBM

03

위험 유형 설명

SHAP 으로 원인을 찾고
고객 유형 정의

SHAP + K-Means

04

마케팅 실험

위험 고객 대상 A/B 테스트로
효과 측정

A/B 테스트

누가 위험한가 → 왜 위험한가 → 어떤 전략을 적용할까

KKBox 구독 데이터 6 개 테이블 통합

출처 : Kaggle — WSDM KKBox's Churn Prediction Challenge

회원

train_v2

회원 번호 · 이탈 여부 (0/1)

members_v3

도시 · 나이 · 성별 · 가입 정보

거래

transactions

결제 방식 · 자동 갱신 · 구독권 (~2/28)

transactions_v2

2017 년 3 월 거래

청취 로그

user_logs

청취 시간 · 청취 곡 수 (~2/28)

user_logs_v2

2017 년 3 월 로그

2 월 말 기록으로 예측하는 3 월 이탈

관찰 기간 · 피쳐 생성

예측 : 3 월 만료 → 30 일 내 재구독 ?

2015-01-01
거래 데이터 시작

2016-12-01
이용 로그 시작

2017-02-28
관찰 종료일

2017-03-31
예측 대상 기간

타겟

is_churn = 1


멤버십 만료 후 30 일 이내 재구독하지 않은 고객

클래스 불균형


이탈 8.95%

정확도 대신 ROC-AUC 를 주 지표로 사용

고객 10 만 명 층화 추출 — 모델링 표본 구성



데이터 누수를 막기 위한 기준



단일 변수보다 강한 특성의 조합

연령대

10 대

25.92%

20 대 13.72%

가입 기간

2~3 년

11.61%

전체 평균보다 높음

가입 경로

registered_via 4

22.43%

3: 17.44% · 9: 12.62%

성별 입력

미입력

6.61%

male 13.03% · female 12.78%

핵심 인사이트

가입 경로 × 가입 기간 × 성별 미입력
세그먼트 이탈률 **20% 이상**


평균보다 2.78%p 높은 수준

결측 플래그끼리 강한 상관

gender_missing · bd_zero · city_1 간 상관 0.87~0.95 →
미입력 자체가 하나의 고객군 특성

거래 횟수가 늘수록 낮아지는 이탈률

거래 횟수별 이탈률



1 회 거래 고객

30.31%

관계가 안정되지 않은 신규 · 초기 고객

복수 거래 고객

8.03%

반복 거래로 관계가 유지되는 고객

가장 강한 신호 : 최근 자동갱신 상태

고객 속성보다 '구독 관계가 약해지는 상태'가 이탈과 더 직접 연결됩니다.

자동갱신 OFF

41.33%

자동갱신을 해제한 고객의 이탈률

자동갱신 ON

4.52%

자동갱신이 켜진 고객의 이탈률

모델링 핵심 변수 `last_auto_renew` + 최근 취소 상태 · 만료까지 남은 기간 · 거래 지속성

활발한 청취, 이탈과 반대로 가는 로그 유무

하루 평균 청취 (중앙값)

17 회

끝까지 들은 곡

19 곡

고유 곡 수


77 분

청취 시간

78.1 %

완곡률

로그 유무별 이탈률



‘로그가 없으면 위험하다’는 가설은 성립하지 않음. 최근성 (recency) 만으로도 뚜렷한 패턴은 없었음.

의미를 살린 결측치 처리와 중복 제거

결측치 처리

변수 특성에 맞는 값으로 대체

city NaN → -1 (기타)

reg_season NaN → 'unknown'

gender NaN → '미입력'

중복 제거

회원 · 거래 · 로그 데이터의 동일 기록 제거

A001 2017-03-01 10:00

A001 2017-03-01 10:00 삭제

A002 2017-03-02 12:30

누적값 → 행동 강도 지표 및 후보 피처 생성

1 단위당 행동 강도

total_payment	→	avg_payment
total_secs	→	avg_daily_secs
total_num_100	→	avg_daily_complete
total_num_unq	→	avg_daily_unq
avg_payment	→	payment_per_plan_day

2 0 에도 의미가 있는 경우

no_unique_song	고유 곡 수 0
zero_plan_days	플랜 기간 0

3 후보 피처

inactive_7days
completed_per_hour
cancel_rate
no_auto_renew_low_activity
long_tenure_low_activity

정확도보다 이탈 고객을 찾아내는 힘

이탈 비율

8.95%

Accuracy 만 보면 착시

문제 유형

Binary

is_churn = 0 / 1

검증 방법

5-fold CV

일반화 성능 비교

평가 지표는 역할을 나눠 사용

ROC-AUC

모델 선택



PR-AUC

불균형 성능 확인



Precision · Recall · F1

실제 개입 기준 (threshold)

후보 모델 선정 — Boosting 계열

XGBoost · LightGBM · CatBoost — 실제 이탈 예측 같은 정형 데이터 분류에서 널리 쓰이는 모델

1 정형 데이터에 강함

수치형 · 범주형이 섞인 Tabular Data 에서 높은 성능

2 복잡한 패턴 포착

청취 × 결제 × 가입 기간 × 자동결제 등 변수 간 상호작용 학습

3 오류를 순차적으로 보완


이전 Tree 가 틀린 고객에 집중
→ 구분이 어려운 위험 고객을 점점 더 잘 분류

4 대규모 데이터에 적합

대규모 고객 데이터에서도 빠르고 높은 성능

40 개 대신 33 개 피쳐 — 성능은 그대로 , 더 단순하게

피쳐 수별 5-fold CV ROC-AUC



전체 40 개

0.8701


최종 33 개

0.8690**차이 0.0011**

CV 표준편차보다 작은 차이 . 중복 · 파생 변수를
줄여 해석성과 유지보수성을 우선했습니다 .

Baseline — CatBoost 와 LightGBM 근소 우위

동일 조건 (33 개 피쳐) 에서 5-fold CV ROC-AUC 비교



결과

상위 두 모델의 차이 0.0013

우열이 크지 않아 CatBoost 와 LightGBM 을
모두 튜닝 대상으로 선정했습니다 .

튜닝 후 LightGBM 선택, threshold 조정

① 하이퍼파라미터 튜닝 (Optuna)

CatBoost

0.8701

+0.0011

LightGBM

0.8708

+0.0016

최종 선택 **LightGBM**

② 임계값 조정 (Threshold Optimization)

지표

기본 0.500

최적 0.282

Precision

0.7895

0.6328

Recall

0.4106

0.5363

F1

0.5402

0.5806Recall **+0.126** F1 **+0.040**

오탐을 일부 허용하고 실제 이탈자를 더 많이 찾아냅니다.

딥러닝 (MLP) 비교

같은 지표 조건에서 정규화 · 드롭아웃 · 조기 종료 적용 여부별 성능

모델	ROC-AUC	Recall	F1
BatchNorm + Dropout MLP	0.8485	0.5536	0.5637
BatchNorm MLP	0.8458	0.3849	0.5157
Dropout MLP	0.8399	0.3777	0.5119
Baseline MLP	0.8338	0.6592	0.5087

최종 DL 모델 BatchNorm + Dropout MLP + EarlyStopping · ROC-AUC 0.8485 로 MLP 중 최고

06 Model Selection

최종 모델


LightGBM 선정

ROC-AUC 0.8708 · threshold 0.282 · Recall 0.536


SHAP 으로 본 이탈의 주요 원인

자동갱신 상태 (last_auto_renew) 와 결제 · 플랜 관련 변수가 예측을 이끄는 신호

① Global Feature Importance (mean |SHAP|)



② Test SHAP Summary (Beeswarm)



위험 고객 4 개 유형 분류 과정

K-Means 클러스터링 수행 과정

01

데이터 구성

Train + Test 를 다시 합쳐
전체 고객 대상



02

피처 선정

행동 지표 피처로 clustering



03

k 탐색

실루엣 점수로 적절한
클러스터 수 탐색



04

k = 4 선정

k=2 가 가장 높았지만,
분류 목적을 고려해 4 개로 선정

K-Means 기반 4 개 위험 고객 유형



Cluster 0 저활동 · 단기 고객

고객 수

3,437 명

위험 고객의 51.3%

평균 위험

45.2%


실제 이탈

51.6%

추천 전략


재이용 유도 캠페인

유형별 평균 |SHAP| Top 10



Cluster 0 대표 고객 위험 요인

개별 Waterfall Plot



이탈 확률

41.9%

실제 이탈 0

주요 SHAP 요인

last_auto_renew = 0 +2.27

activity_days = 14 +0.22

payment_per_plan_day = 6.0 +0.16

자동갱신 해제가 가장 크게 작용하고, 낮은 활동량도 함께 영향을 준 사례

마케팅 전략

개인화 음악 추천 · 앱 재방문 유도 메시지 · 접속 유도 미션형
프로모션

Cluster 1 반복 거래 · 취소 고객

고객 수

681 명

위험 고객의 10.2%

평균 위험

73.7%


실제 이탈

75.8%

추천 전략


취소 시점 방어

유형별 평균 |SHAP| Top 10



Cluster 1 대표 고객 위험 요인

개별 Waterfall Plot



이탈 확률

70.6%

실제 이탈 1

주요 SHAP 요인

last_is_cancel = 1 +3.37

cancel_on_last_date = 1 +0.87

payment_per_plan_day = 4.74 +0.09

최근 취소 행동 관련 변수가 압도적으로 크게 작용한 사례

마케팅 전략

취소 시점에 직접 개입하는 이탈 방어

Cluster 2 장기 플랜 · 고결제 고객

고객 수

1,748 명

위험 고객의 26.1%

평균 위험

84.4%


실제 이탈

86.3%

추천 전략


고가치 고객 선제 유지

유형별 평균 |SHAP| Top 10



Cluster 2 대표 고객 위험 요인

개별 Waterfall Plot



이탈 확률

85.3%

실제 이탈 1

주요 SHAP 요인

last_auto_renew = 0 **+3.13**

last_plan_days = 410 **+1.06**

avg_payment = 1788 **+0.45**

자동갱신 해제 · 긴 플랜 기간 · 높은 결제금액이 함께 작용한 사례

마케팅 전략

VIP 혜택 · 독점 / 선공개 콘텐츠

Cluster 3 장기 관계 · 고빈도 고객

고객 수

830 명

위험 고객의 12.4%


평균 위험 **57.0%**

실제 이탈 **63.7%**

추천 전략


장기 충성도 강화

유형별 평균 |SHAP| Top 10



Cluster 3 대표 고객 위험 요인

개별 Waterfall Plot



이탈 확률

52.2%

실제 이탈 0

주요 SHAP 요인

last_auto_renew = 0

+2.66

last_plan_days = 60

+0.58

avg_payment = 225

+0.26

장기 고객도 자동갱신 · 플랜 기간 · 결제 특성이 위험 신호로 작용한 사례

마케팅 전략

장기 충성도 강화 · 개인화 recap

KKeeper — 예측에서 실행까지 하나의 흐름


핵심 기능 1 전략 매칭



STEP 01

마케팅 설계

마케팅 방안과 대상 조건 입력



STEP 02

고객 매칭

전략이 잘 통할 고객 유형 추천



STEP 03

실험 관리

두 그룹으로 나눠 실제 효과 검증



STEP 04

라이브러리

효과가 확인된 전략 저장과 재활용

이탈 모델 + 4 개 고객 유형이 마케팅 설계와 고객 매칭의 기반이 됩니다 .